

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего
образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Кафедра ИУ5 «Системы обработки информации и управления»
Дисциплина «Технологии машинного обучения»

ОТЧЕТ

по научно-исследовательской работе студента
**на тему: «Анализ данных California Housing Prices и построение моделей
машинного обучения для задач классификации и регрессии»**

Студент: Юрченко К.Г.

Группа: ИУ5-64Б

Руководитель: Гапанюк Ю.Е.

Москва, 2026

ЗАДАНИЕ НА НИРС

Студент: Юрченко К.Г., группа ИУ5-64Б.

Тема исследования: «Анализ данных California Housing Prices и построение моделей машинного обучения для задач классификации и регрессии».

Вид исследования: типовое исследование по дисциплине «Технологии машинного обучения», предполагающее решение задач машинного обучения на основе выбранного набора данных.

Цель работы: разработать и оценить модели классификации и регрессии для анализа стоимости жилья в округах Калифорнии по числовым признакам, полученным по данным переписи населения.

Задачи работы:

- 1) выбрать набор данных и обосновать актуальность задачи;
- 2) провести разведочный анализ данных и проверить наличие пропусков;
- 3) выполнить корреляционный анализ и подготовку признаков;
- 4) выбрать и обосновать метрики качества классификации и регрессии;
- 5) построить baseline-решения не менее чем для пяти моделей, включая ансамблевые модели;
- 6) провести подбор гиперпараметров с использованием кросс-валидации;
- 7) сравнить качество baseline-моделей и моделей после подбора гиперпараметров;
- 8) подготовить веб-приложение для демонстрации выбранной модели.

Исходные данные: набор California Housing Prices, доступный через `fetch_california_housing` библиотеки `scikit-learn`.

Результаты работы: отчет, Jupyter Notebook с вычислительным экспериментом, файл веб-приложения Streamlit и материалы проекта.

Руководитель НИРС: Гапанюк Ю.Е.

Студент: Юрченко К.Г.

СОДЕРЖАНИЕ

Введение	4
1 Постановка задачи и описание набора данных	5
1.1 Выбор темы и набора данных	5
1.2 Цель, объект и предмет исследования	6
2 Разведочный анализ и подготовка данных	7
2.1 Структура данных	7
2.2 Анализ пропусков и предварительная обработка	8
2.3 Корреляционный анализ	8
3 Методика построения моделей	10
3.1 Метрики качества	10
3.2 Рассматриваемые модели	10
3.3 Схема эксперимента	11
4 Результаты моделирования	12
4.1 Baseline-решение	12
4.2 Подбор гиперпараметров	14
4.3 Анализ лучшей модели	15
5 Веб-приложение для демонстрации модели	17
Заключение	18
Список использованных источников	19
Приложение А. Фрагмент кода веб-приложения	20

ВВЕДЕНИЕ

Методы машинного обучения широко применяются для анализа табличных данных, в которых необходимо прогнозировать числовые значения или относить объекты к заранее заданным классам. В рамках дисциплины «Технологии машинного обучения» типовое исследование включает выбор набора данных, разведочный анализ, подготовку признаков, построение нескольких моделей, подбор гиперпараметров и итоговое сравнение качества.

В настоящей работе рассматривается учебная задача анализа данных California Housing Prices. Набор данных содержит сведения о жилых районах Калифорнии, включая медианный доход, возраст домов, среднее число комнат, численность населения и географические координаты. На основе этих признаков решаются две задачи: бинарная классификация жилья на «дорогое» и «доступное» и регрессия медианной стоимости жилья.

Актуальность учебной задачи состоит в том, что она позволяет на реальном табличном наборе данных исследовать полный цикл построения моделей машинного обучения. Полученные модели рассматриваются исключительно как демонстрация методов анализа данных и не являются системой оценки недвижимости для принятия финансовых решений.

1 ПОСТАНОВКА ЗАДАЧИ И ОПИСАНИЕ НАБОРА ДАННЫХ

1.1 Выбор темы и набора данных

Тема НИРС: «Анализ данных California Housing Prices и построение моделей машинного обучения для задач классификации и регрессии». Тема соответствует типовой схеме исследования: решается задача машинного обучения на выбранном наборе данных, проводится разведочный анализ, строится несколько моделей, выполняется подбор гиперпараметров и формируются выводы по выбранным метрикам.

В качестве исходных данных выбран набор California Housing Prices. Он содержит 20 640 объектов, восемь числовых признаков и целевой признак MedHouseVal, отражающий медианную стоимость жилья в районе в единицах 100 тыс. долларов. Для задачи классификации сформирован дополнительный целевой признак price_class: значение 1 соответствует объектам со стоимостью выше медианы, значение 0 - объектам со стоимостью не выше медианы.

Признаки набора данных характеризуют медианный доход домохозяйств, возраст домов, среднее число комнат и спален, численность населения, среднюю занятость жилья и географические координаты. Все признаки являются числовыми, поэтому отдельное кодирование категориальных признаков не требуется.

Таблица 1 - Основные характеристики набора данных

Показатель	Значение
Число объектов	20 640
Число исходных признаков	8
Число признаков, использованных в моделях	7
Типы задач	Бинарная классификация, регрессия
Целевой признак классификации	price_class
Положительный класс	1, жилье дороже медианы
Целевой признак регрессии	MedHouseVal
Медианная стоимость	1,797 (\$100k)
Число объектов по классам	0 - 10 322, 1 - 10 318
Число пропусков	0
Размеры выборок	обучающая - 16 512, тестовая - 4 128

1.2 Цель, объект и предмет исследования

Цель работы - построить и сравнить модели машинного обучения, способные по набору числовых признаков решать две задачи: прогнозировать принадлежность объекта к классу дорогого жилья и оценивать медианную стоимость жилья.

Объект исследования - табличные данные California Housing Prices. Предмет исследования - методы машинного обучения для классификации и регрессии, включая линейные модели, метод ближайших соседей, метод опорных векторов, деревья решений и ансамблевые модели.

Практический результат работы - воспроизводимый вычислительный эксперимент, таблицы и графики качества моделей, а также веб-приложение, позволяющее изменять гиперпараметры выбранной модели и наблюдать изменение метрик на тестовой выборке.

2 РАЗВЕДОЧНЫЙ АНАЛИЗ И ПОДГОТОВКА ДАННЫХ

2.1 Структура данных

Все признаки в наборе данных являются числовыми. Для задачи классификации классы сформированы по медиане целевого признака `MedHouseVal`, поэтому распределение объектов по классам близко к равномерному. В обучающей выборке класс 0 содержит 8258 объектов, класс 1 - 8254 объекта, что соответствует практически идеальному балансу классов.




Рисунок 1 - Распределение объектов по классам `price_class`

Географические координаты позволяют визуально оценить пространственную структуру стоимости жилья. На графике видны районы с более высокой медианной стоимостью, что делает признаки `Latitude` и `Longitude` полезными для моделей, несмотря на их взаимную корреляцию.




Рисунок 2 - Географическое распределение медианной стоимости жилья

2.2 Анализ пропусков и предварительная обработка

Проверка обучающей и тестовой выборок показала отсутствие пропущенных значений по всем признакам и целевым переменным. Удаление дубликатов не изменило размер набора данных: до и после проверки количество строк составило 20 640.

Для подготовки признаков использовано масштабирование `MinMaxScaler`, приводящее числовые признаки к диапазону $[0, 1]$. Масштабирование особенно важно для моделей, основанных на расстояниях и отступах, например `KNN`, `SVC` и `SVR`. Для построения моделей из набора признаков исключен `AveBedrms`, поскольку он имеет высокую корреляцию с `AveRooms`.

2.3 Корреляционный анализ

Корреляционный анализ выполнен для исходных и масштабированных данных. Масштабирование не изменяет коэффициенты корреляции, поэтому структура связей между признаками и целевыми переменными сохраняется.

Наиболее выраженная связь с целевыми переменными наблюдается у признака MedInc, что ожидаемо для задачи оценки стоимости жилья.

Таблица 2 - Основные результаты корреляционного анализа

Связь	Коэффициент	Интерпретация
MedInc и MedHouseVal	0,69	медианный доход является главным предиктором стоимости
MedInc и price_class	0,69	высокий доход связан с дорогим жильем
AveRooms и AveBedrms	0,85	признаки сильно связаны между собой
Latitude и Longitude	-0,92	координаты отражают географическую структуру штата
Latitude и price_class	-0,14	слабая, но заметная связь с классом
Longitude и price_class	0,13	слабая, но заметная связь с классом




Рисунок 3 - Корреляционная матрица масштабированных признаков и целевых переменных

Корреляционный анализ подтверждает возможность построения моделей машинного обучения. При этом часть зависимостей имеет нелинейный характер, поэтому в эксперимент включены не только линейные модели, но и методы деревьев, ансамбли и модели на основе опорных векторов.

3 МЕТОДИКА ПОСТРОЕНИЯ МОДЕЛЕЙ

3.1 Метрики качества

Так как в работе решаются задачи классификации и регрессии, используются две группы метрик. Для классификации применяются precision, recall, F1 и ROC AUC. Для регрессии применяются MAE, MSE и коэффициент детерминации R2.

Таблица 3 - Используемые метрики качества

Задача	Метрика	Смысл метрики	Назначение в работе
Классификация	Precision	TP / (TP + FP)	контроль ложных отнесений к дорогому жилью
Классификация	Recall	TP / (TP + FN)	контроль пропусков дорогого жилья
Классификация	F1	гармоническое среднее precision и recall	баланс точности и полноты
Классификация	ROC AUC	площадь под ROC-кривой	оценка качества ранжирования
Регрессия	MAE	средняя абсолютная ошибка	интерпретируемая ошибка прогноза
Регрессия	MSE	средняя квадратичная ошибка	штраф за большие отклонения
Регрессия	R2	доля объясненной дисперсии	общая оценка качества регрессии

Для классификации основное внимание уделяется ROC AUC и F1, так как классы сбалансированы и важно оценивать не только итоговую метку, но и качество ранжирования объектов. Для регрессии основной показатель - R2, а MAE и MSE используются для дополнительной интерпретации величины ошибки.

3.2 Рассматриваемые модели

Для выполнения требования о сравнении нескольких моделей использованы шесть алгоритмов для классификации и шесть алгоритмов для регрессии, включая ансамблевые модели. Такой набор позволяет сравнить линейные, метрические, ядерные, древовидные и ансамблевые методы.

Таблица 4 - Перечень моделей, использованных в эксперименте

Модель	Тип модели	Задачи	Ключевые гиперпараметры
Logistic / Linear Regression	линейная модель	классификация, регрессия	C для классификации
KNN	метрический метод	классификация, регрессия	n_neighbors
SVC / SVR	метод опорных векторов	классификация, регрессия	C, gamma
Decision Tree	дерево решений	классификация, регрессия	max_depth, min_samples_leaf

Random Forest	ансамбль деревьев	классификация, регрессия	n_estimators, max_depth
Gradient Boosting	бустинг деревьев	классификация, регрессия	n_estimators, learning_rate

3.3 Схема эксперимента

Эксперимент выполнен по следующей схеме. Сначала набор данных разделяется на обучающую и тестовую выборки в отношении 80 % и 20 %. Для задачи классификации используется стратификация по price_class, что сохраняет баланс классов. Затем числовые признаки масштабируются с помощью MinMaxScaler.

На первом этапе все модели обучаются с базовыми параметрами, что позволяет получить baseline-оценку. На втором этапе для KNN-моделей выполняется GridSearchCV с пятикратной кросс-валидацией. Для классификации оптимизируется ROC AUC, а для регрессии - отрицательная средняя квадратичная ошибка. После выбора лучшего числа соседей модели оцениваются на отложенной тестовой выборке.

Фиксация random_state = 42 обеспечивает воспроизводимость разбиения и обучения стохастических моделей. Тестовая выборка не используется при выборе гиперпараметров, что позволяет рассматривать итоговые значения метрик как независимую оценку качества.

4 РЕЗУЛЬТАТЫ МОДЕЛИРОВАНИЯ

4.1 Baseline-решение

На первом этапе модели обучались без целенаправленного подбора гиперпараметров. Результаты baseline-эксперимента для задачи классификации представлены в таблице 5. В таблицах результатов используются сокращения: LogR - Logistic Regression, SVC - Support Vector Classifier, Tree - Decision Tree, RF - Random Forest, GB - Gradient Boosting.

Таблица 5 - Качество baseline-моделей классификации на тестовой выборке

Мод.	Prec.	Rec.	F1	ROC AUC
RF	0,909	0,897	0,903	0,966
GB	0,888	0,884	0,886	0,957
Tree	0,872	0,848	0,860	0,862
KNN_5	0,854	0,833	0,844	0,918
SVC	0,831	0,818	0,825	0,911
LogR	0,812	0,805	0,809	0,898

Лучший baseline-результат по F1 и ROC AUC получен моделью Random Forest. Gradient Boosting также показывает высокое качество и занимает второе место по большинству метрик. Это подтверждает, что ансамблевые методы лучше улавливают нелинейные связи между доходом, географическим положением и стоимостью жилья.




Рисунок 4 - Сравнение ROC AUC моделей классификации

Для задачи регрессии результаты baseline-эксперимента представлены в таблице 6. Значения MAE и MSE должны быть как можно меньше, а значение R2 - как можно больше.

Таблица 6 - Качество baseline-моделей регрессии на тестовой выборке

Мод.	MAE	MSE	R2
RF	0,325	0,243	0,817
GB	0,362	0,265	0,800
KNN_5	0,419	0,381	0,713
SVR	0,445	0,430	0,675
Tree	0,450	0,500	0,622
LR	0,534	0,512	0,614

Наилучший результат в задаче регрессии показал Random Forest: MAE = 0,325, MSE = 0,243 и R2 = 0,817. Поскольку целевая переменная измеряется в единицах 100 тыс. долларов, MAE = 0,325 соответствует средней абсолютной ошибке порядка 32,5 тыс. долларов.




Рисунок 5 - Сравнение R2 моделей регрессии

4.2 Подбор гиперпараметров

На втором этапе выполнен подбор числа соседей для KNN-моделей. Для классификации рассматривались значения `n_neighbors` от 1 до 475 с шагом 25, качество на кросс-валидации оптимизировалось по ROC AUC. Лучшее значение параметра `n_neighbors` составило 25.

Для регрессии рассматривались значения `n_neighbors` от 1 до 476 с шагом 25, качество оптимизировалось по отрицательной MSE. Лучшее значение параметра `n_neighbors` составило 26. Итоговое сравнение KNN-моделей представлено в таблице 7.

Таблица 7 - Сравнение KNN до и после подбора гиперпараметров

Задача	Модель	Ключевой параметр	Метрика 1	Метрика 2	Метрика 3
Классификация	KNN_5	<code>n_neighbors=5</code>	F1=0,844	ROC AUC=0,918	Prec.=0,854
Классификация	KNN_25	<code>n_neighbors=25</code>	F1=0,840	ROC AUC=0,923	Prec.=0,844
Регрессия	KNN_5	<code>n_neighbors=5</code>	MAE=0,419	MSE=0,381	R2=0,713
Регрессия	KNN_26	<code>n_neighbors=26</code>	MAE=0,429	MSE=0,383	R2=0,711




Рисунок 6 - Зависимость ROC AUC от числа соседей для KNN-классификации

Подбор гиперпараметров улучшил ROC AUC KNN-классификатора с 0,918 до 0,923, однако F1 на тестовой выборке немного снизился. Для KNN-регрессора выбранная по кросс-валидации конфигурация не улучшила тестовое качество относительно базового значения $k=5$. Это показывает, что выигрыш по кросс-валидации не всегда гарантирует улучшение на конкретной отложенной выборке.

4.3 Анализ лучшей модели

Лучшей моделью классификации стала Random Forest. Значения метрик на тестовой выборке: Precision = 0,909, Recall = 0,897, F1 = 0,903 и ROC AUC = 0,966. Высокие значения precision и recall показывают, что модель одновременно контролирует ложные срабатывания и пропуски объектов класса дорогого жилья.

Лучшей моделью регрессии также стала Random Forest. Она достигла $R^2 = 0,817$ и имеет наименьшие значения MAE и MSE среди рассмотренных моделей. Такой результат объясняется способностью ансамбля деревьев учитывать нелинейные зависимости и взаимодействия признаков без явного задания функциональной формы.




Рисунок 7 - ROC-кривая и нормированная матрица ошибок модели Random Forest

Для итогового учебного решения может быть выбрана модель Random Forest, так как она показывает лучшие результаты как в задаче классификации, так и в задаче регрессии. Ограничением исследования является использование только одного открытого набора данных и отсутствие внешней независимой проверки.

5 ВЕБ-ПРИЛОЖЕНИЕ ДЛЯ ДЕМОНСТРАЦИИ МОДЕЛИ

Для демонстрации модели подготовлено веб-приложение на Streamlit. Приложение загружает набор данных California Housing Prices, формирует целевой признак `price_class`, выполняет разбиение на обучающую и тестовую выборки, масштабирует признаки и обучает модель Random Forest.

В боковой панели пользователь может выбрать тип задачи: классификацию или регрессию. Также доступны гиперпараметры `n_estimators`, `max_depth` и `min_samples_leaf`. После изменения параметров модель переобучается, а на странице обновляются метрики качества. Для классификации выводятся Precision, Recall, F1 и ROC AUC, для регрессии - MAE, MSE и R2.

Файл веб-приложения: `streamlit_app_yurchenko.py`. Для запуска в локальной среде необходимо установить зависимости из `requirements_yurchenko.txt` и выполнить команду:

```
streamlit run streamlit_app_yurchenko.py
```

Приложение является учебной демонстрацией и не предназначено для принятия финансовых решений о покупке или продаже недвижимости.

ЗАКЛЮЧЕНИЕ

В ходе НИРС выполнен полный цикл типового исследования по дисциплине «Технологии машинного обучения». Был выбран набор California Housing Prices, сформулированы задачи бинарной классификации и регрессии, проведены разведочный и корреляционный анализы, подготовлены признаки и определены метрики качества.

В эксперименте обучены шесть моделей классификации и шесть моделей регрессии: линейные модели, KNN, SVC/SVR, Decision Tree, Random Forest и Gradient Boosting. Требование о применении не менее пяти моделей и ансамблевых методов выполнено. Для KNN-моделей проведен подбор гиперпараметра `n_neighbors` с помощью GridSearchCV и пятикратной кросс-валидации.

Лучший результат в задаче классификации показала модель Random Forest: Precision = 0,909, Recall = 0,897, F1 = 0,903 и ROC AUC = 0,966. Лучший результат в задаче регрессии также показала модель Random Forest: MAE = 0,325, MSE = 0,243 и R2 = 0,817.

Подготовлено веб-приложение Streamlit, позволяющее изменять гиперпараметры модели и наблюдать изменение качества. Полученные результаты подтверждают, что выбранный набор признаков хорошо подходит для учебной демонстрации методов машинного обучения. Ограничением исследования является отсутствие внешней проверки и необходимость учитывать, что модели не предназначены для практической финансовой оценки недвижимости без дополнительной валидации.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Типовое задание на НИРС по дисциплине «Технологии машинного обучения» [Электронный ресурс]. - URL: https://github.com/ugapanyuk/courses_current/wiki/TMO_NIRS (дата обращения: 21.05.2026).
2. Опорный пример для выполнения проекта по анализу данных [Электронный ресурс]. - URL: https://github.com/ugapanyuk/courses_current/blob/main/notebooks/ml_project_example/project_classification_regression.ipynb (дата обращения: 21.05.2026).
3. Scikit-learn documentation. fetch_california_housing [Электронный ресурс]. - URL: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.fetch_california_housing.html (дата обращения: 21.05.2026).
4. Kaggle. California Housing Prices [Электронный ресурс]. - URL: <https://www.kaggle.com/datasets/camnugent/california-housing-prices> (дата обращения: 21.05.2026).
5. Scikit-learn documentation. Metrics and scoring: quantifying the quality of predictions [Электронный ресурс]. - URL: https://scikit-learn.org/stable/modules/model_evaluation.html (дата обращения: 21.05.2026).
6. Scikit-learn documentation. GridSearchCV [Электронный ресурс]. - URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html (дата обращения: 21.05.2026).
7. Scikit-learn documentation. RandomForestClassifier [Электронный ресурс]. - URL: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html> (дата обращения: 21.05.2026).
8. Streamlit documentation [Электронный ресурс]. - URL: <https://docs.streamlit.io/> (дата обращения: 21.05.2026).

ПРИЛОЖЕНИЕ А. ФРАГМЕНТ КОДА ВЕБ-ПРИЛОЖЕНИЯ

Ниже приведен фрагмент файла `streamlit_app_yurchenko.py`, демонстрирующий загрузку данных, изменение гиперпараметров и переобучение модели в интерфейсе Streamlit.

```
"""Streamlit-демонстрация для НИРС по ТМО.
Тема: анализ данных California Housing Prices.
"""
import pandas as pd
import streamlit as st
from sklearn.datasets import fetch_california_housing
from sklearn.ensemble import RandomForestClassifier, RandomForestRegressor
from sklearn.metrics import precision_score, recall_score, f1_score, roc_auc_score
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler

RANDOM_STATE = 42
FEATURES = [
    "MedInc", "HouseAge", "AveRooms", "Population",
    "AveOccup", "Latitude", "Longitude"
]

@st.cache_data
def load_dataset():
    dataset = fetch_california_housing(as_frame=True)
    data = dataset.frame.copy()
    median_price = data["MedHouseVal"].median()
    data["price_class"] = (data["MedHouseVal"] > median_price).astype(int)
    return data, median_price

st.set_page_config(page_title="НИРС ТМО: California Housing", layout="wide")
st.title("California Housing: классификация и регрессия")
st.caption("Учебная демонстрация модели Random Forest.")

data, median_price = load_dataset()
task = st.sidebar.selectbox("Задача", ["Классификация", "Регрессия"])
n_estimators = st.sidebar.slider("n_estimators", 50, 300, 100, 50)
max_depth_value = st.sidebar.slider("max_depth", 2, 30, 10, 1)
min_samples_leaf = st.sidebar.slider("min_samples_leaf", 1, 20, 1, 1)

X = data[FEATURES]
y = data["price_class"] if task == "Классификация" else data["MedHouseVal"]
stratify = y if task == "Классификация" else None
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=RANDOM_STATE, stratify=stratify
)

scaler = MinMaxScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

if task == "Классификация":
    model = RandomForestClassifier(
        n_estimators=n_estimators, max_depth=max_depth_value,
        min_samples_leaf=min_samples_leaf, random_state=RANDOM_STATE
    )
    model.fit(X_train_scaled, y_train)
    y_pred = model.predict(X_test_scaled)
    y_score = model.predict_proba(X_test_scaled)[:, 1]
    st.metric("Precision", f"{precision_score(y_test, y_pred):.3f}")
    st.metric("Recall", f"{recall_score(y_test, y_pred):.3f}")
    st.metric("F1", f"{f1_score(y_test, y_pred):.3f}")
    st.metric("ROC AUC", f"{roc_auc_score(y_test, y_score):.3f}")
else:
```

```

model = RandomForestRegressor(
    n_estimators=n_estimators, max_depth=max_depth_value,
    min_samples_leaf=min_samples_leaf, random_state=RANDOM_STATE
)
model.fit(X_train_scaled, y_train)
y_pred = model.predict(X_test_scaled)
st.metric("MAE", f"{mean_absolute_error(y_test, y_pred):.3f}")
st.metric("MSE", f"{mean_squared_error(y_test, y_pred):.3f}")
st.metric("R2", f"{r2_score(y_test, y_pred):.3f}")

```